

Prevendo a Qualidade de Vinhos com Dados

Vitivinícola

Bruno Ricardo de Oliveira

Tech Challenge – Fase 2 - Grupo 143

Pós Tech FIAP - Data Analytics



O PROBLEMA DE NEGÓCIO



A qualidade do vinho é avaliada por especialistas, em análise sensorial.



Processo subjetivo, lento e caro — difícil de padronizar em escala.



Pergunta de negócio: conseguimos antecipar quais lotes serão de alta qualidade usando apenas os **exames físico-químicos** que já fazemos hoje?



Valor: priorizar lotes promissores, reduzir custo de avaliação e apoiar o controle de qualidade.

OS DADOS QUE TEMOS DISPONÍVEIS

Wine Quality Dataset: 1.143 linhas com dados dos vinhos avaliados por especialistas;

11 medições físico-químicas por amostra;


Nota de qualidade de 3 a 8 dada por especialistas.

Sem valores ausentes;

Removidas 125 amostras idênticas para garantir uma avaliação honesta → **1.018 amostras** finais.

O QUE A ANÁLISE EXPLORATÓRIA NOS REVELOU?


- Teor alcoólico é o fator mais associado à qualidade: vinhos melhores tendem a ter mais álcool.
- Acidez volátil tem relação inversa: excesso derruba a qualidade.
- Sulfatos e ácido cítrico também acompanham vinhos melhor avaliados.
- Correlações coerentes com o conhecimento enológico — dão confiança ao modelo.



A DEFINIÇÃO DO ALVO



- Transformamos a nota em uma pergunta de **sim ou não**:
- Apenas 13% dos vinhos são de alta qualidade → problema: desbalanceado.
- Consequência: um modelo "preguiçoso" que sempre diz "não é alta qualidade" acerta 87% das vezes, mas **não serve para nada** — nunca identifica os vinhos bons. Por isso não olhamos só a acurácia.

Alta qualidade	Baixa/Média qualidade
nota ≥ 7	nota < 7



A ABORDAGEM

- Separamos os dados em treino (80%) e teste (20%), mantendo a proporção de vinhos bons.
- Padronizamos as medições e testamos 4 modelos de inteligência artificial + um modelo de referência (baseline).
- Ajustamos cada modelo com validação cruzada.
- Comparamos todos em dados nunca vistos no treino.
- Tudo **reprodutível** e sem "vazamento" de informação.



MODELOS TESTADOS E RESULTADOS

ROC-AUC de 0,92: a chance de o modelo ranquear corretamente um vinho bom acima de um ruim é de 92%.

Acurácia de 87,3 %

Todos os modelos superam largamente o baseline.


Modelo	ROC-AUC	Recall (acha vinhos bons)
Random Forest (escolhido)	0,92	63%
SVM	0,90	44%
Gradient Boosting	0,89	44%
Regressão Logística	0,89	78%
Baseline	—	0%

O MELHOR MODELO: RANDOM FOREST

Melhor equilíbrio geral (ROC-AUC = 0,92).


Identifica ~63% dos vinhos de alta qualidade no teste.

Matriz de confusão mostra bom acerto na classe de interesse mesmo sendo rara.



O QUE MOVE A QUALIDADE (INSIGHTS)

Fatores mais influentes segundo o modelo:
Teor alcoólico — o maior sinal de qualidade.
Acidez volátil — quanto menor, melhor.
Sulfatos — associados a vinhos melhor avaliados.
Ácido cítrico — contribui positivamente.
Leitura de negócio: o controle desses parâmetros na produção tem relação direta com a qualidade percebida.



RISCOS E LIMITAÇÕES

- Desbalanceamento: poucos exemplos de vinhos excelentes limitam a precisão.
- Base de vinho tinto de uma origem — não generaliza automaticamente para vinho branco ou outras regiões.
- A qualidade sensorial tem componente subjetivo que nenhum dado físico-químico captura totalmente.
- O modelo apoia, não substitui, o especialista.

RECOMENDAÇÃO FINAL

- Adotar o modelo como triador automático de lotes: sinaliza os candidatos a alta qualidade para inspeção prioritária.
- Ganho: foco do enólogo nos casos que mais importam e padronização do controle de qualidade.
- Próximos passos: coletar mais amostras de alta qualidade, calibrar o ponto de corte conforme o custo do erro e estender ao vinho branco.

Prevendo a Qualidade de Vinhos com Dados

Obrigado!

Dúvidas estou à disposição.

Link do Repositório do projeto no Github:

<https://github.com/bruno88rick/wine-Quality-classification>

