

Relatório Técnico Detalhado

Classificação da Qualidade de Vinhos — Tech Challenge Fase 2 (FIAP)

Autor: Bruno Ricardo de Oliveira — Grupo 143

1. Definição do Problema

- **Tarefa:** classificação binária supervisionada.
- **Unidade de análise:** amostras de vinho.
- **Alvo:** 1 (alta qualidade) se `quality >= 7`; caso contrário 0 (baixa/média).
- **Objetivo de negócio:** triar automaticamente lotes com alta probabilidade de qualidade elevada, apoiando a decisão do enólogo.

2. Dados

Item	Valor
Fonte	Wine Quality Dataset (vinho tinto), <code>data/WineQT.csv</code>
Registros brutos	1.143
Colunas brutas	13 (11 features + <code>quality</code> + <code>Id</code>)
Valores ausentes	0
Duplicatas removidas (após descartar <code>Id</code>)	125
Registros usados na modelagem	1.018
Features	fixed acidity, volatile acidity, citric acid, residual sugar, chlorides, free sulfur dioxide, total sulfur dioxide, density, pH, sulphates, alcohol

Item	Valor
Prevalência da classe positiva	~13,2%

Justificativa da remoção de duplicatas: sem a coluna **Id**, diversas linhas apresentam perfil físico-químico idêntico. Mantê-las permitiria que a mesma amostra caísse simultaneamente em treino e teste, gerando *data leakage* e inflando artificialmente as métricas. A remoção precede o split.

3. Metodologia

3.1 Divisão treino/teste

- `train_test_split` com `test_size=0.20`, `stratify=y`, `random_state=42`.
- Treino: 814 amostras | Teste: 204 amostras (proporção de classes preservada).

3.2 Pré-processamento

- `StandardScaler` encapsulado em `Pipeline`, ajustado **apenas** no treino de cada fold — evita vazamento de estatísticas do teste.
- Sem imputação (não há ausentes) e sem codificação (todas as features são numéricas contínuas).
- **Outliers:** quantificados por variável pelo método do IQR (`results/outliers_summary.csv`); os maiores percentuais aparecem em `residual_sugar` (~9,6%) e `chlorides` (~6,7%). **Não** são removidos automaticamente: no domínio enológico costumam representar perfis físico-químicos reais e podem carregar sinal útil. O tratamento adequado é a padronização (`StandardScaler`), já aplicada nos modelos sensíveis à escala.

3.3 Modelos e busca de hiperparâmetros

Seleção por `GridSearchCV` com `StratifiedKFold(n_splits=5, shuffle=True, random_state=42)`, otimizando **ROC-AUC**. Desbalanceamento

tratado com `class_weight="balanced"` (Regressão Logística, SVM, Random Forest).

Modelo	Grid de hiperparâmetros	Melhores parâmetros
Regressão Logística	$C \in \{0.01, 0.1, 1, 10\}$	$C=0.01$
SVM (RBF) ¹	$C \in \{0.5, 1, 10\}$, $\text{gamma} \in \{\text{scale}, 0.1\}$	$C=0.5$, $\text{gamma}=\text{scale}$
Random Forest	$n_estimators \in \{300, 500\}$, $\text{max_depth} \in \{\text{None}, 8, 15\}$, $\text{min_samples_leaf} \in \{1, 2\}$	$n_estimators=500$, $\text{max_depth}=15$, $\text{min_samples_leaf}=2$
Gradient Boosting	$n_estimators \in \{200, 400\}$, $\text{learning_rate} \in \{0.05, 0.1\}$, $\text{max_depth} \in \{2, 3\}$	$n_estimators=200$, $\text{lr}=0.05$, $\text{max_depth}=2$

¹ O SVM é envolvido por `CalibratedClassifierCV (method="sigmoid")` para obter `predict_proba` calibrado sem recorrer ao parâmetro `probability=True`, descontinuado no scikit-learn ≥ 1.9 .

4. Métricas

4.1 Validação cruzada (ROC-AUC, treino)

Modelo	ROC-AUC (média)	Desvio
Regressão Logística	0,880	0,041
Random Forest	0,874	0,036
SVM (RBF)	0,872	0,044
Gradient Boosting	0,867	0,041

4.2 Conjunto de teste (204 amostras)

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Random Forest	0,873	0,515	0,630	0,567	0,919
SVM (RBF)	0,907	0,750	0,444	0,558	0,904
Gradient Boosting	0,892	0,632	0,444	0,522	0,893
Regressão Logística	0,794	0,368	0,778	0,500	0,892
Baseline (majoritária)	0,868	0,000	0,000	0,000	—

Classification report do melhor modelo (Random Forest):

	precision	recall	f1-score	support
Baixa/Media (0)	0.9415	0.9096	0.9253	177
Alta (1)	0.5152	0.6296	0.5667	27
accuracy			0.8725	204
macro avg	0.7283	0.7696	0.7460	204
weighted avg	0.8851	0.8725	0.8778	204

4.3 Justificativa das métricas

A **acurácia é enganosa** neste problema: o baseline majoritário atinge 0,868 de acurácia com **recall zero** para a classe de interesse. Priorizamos **ROC-AUC** (desempenho independente de limiar e robusto a desbalanceamento) e **recall/F1** da classe "Alta". O Random Forest foi escolhido por apresentar o maior ROC-AUC no teste (0,919), com bom equilíbrio entre precisão e recall.

5. Interpretação (importância das variáveis — Random Forest)

Posição	Variável	Importância
1	alcohol	0,216
2	volatile acidity	0,137
3	sulphates	0,134
4	citric acid	0,101
5	density	0,084

Posição	Variável	Importância
6	chlorides	0,069
7	total sulfur dioxide	0,068

Leitura enológica: maior **teor alcoólico** e **sulfatos**, e **menor acidez volátil**, associam-se a vinhos melhor avaliados — consistente com a matriz de correlação da EDA. Isso confere plausibilidade ao modelo e oferece alavancas de processo produtivo.

6. Reprodutibilidade

- Semente fixa (**random_state=42**) em split, CV e modelos estocásticos.
- Pré-processamento e modelo encapsulados em um único **Pipeline**.
- Versões das bibliotecas registradas em **requirements.txt**.
- Execução única via **python src/train_classification_model.py**.
- Artefatos versionáveis: **results/metrics.json**, **results/model_comparison.csv**, **results/classification_report.txt**, figuras em **results/figures/** e o modelo serializado em **models/model.joblib**.

7. Limitações e Riscos

- **Desbalanceamento severo** (~13% positivos): precisão da classe "Alta" limitada; poucos exemplos de vinhos excelentes.
- **Generalização:** base restrita a vinho de uma origem; não validada para outros tipos ou outras regiões/safras.
- **Subjetividade do alvo:** a nota sensorial embute julgamento humano não totalmente explicável por variáveis físico-químicas.
- **Uso pretendido:** ferramenta de **apoio/triagem**, não decisão autônoma.

8. Próximos Passos

1. Ampliar a amostra de vinhos de alta qualidade.
2. Comparar **class_weight** com reamostragem (SMOTE/undersampling).
3. Calibrar o limiar de decisão conforme o custo de falso positivo vs. falso negativo (curva precision-recall).

4. Estender a outros tipos de vinhos e explorar *feature engineering*.